

# SVM con Kernel

Héctor Maravillo

# Maquina de Soporte Vectorial (SVM)

SVM hard-margin primal

SVM con  
Kernel

Héctor  
Maravillo

sea  $X = \{\mathbf{x}_1, \dots, \mathbf{x}_n\}$  un conjunto de patrones, tal que  $\mathbf{x}_i \in \mathbb{R}^l$ , para  $i = 1, \dots, n$ . Sea  $\mathbf{w} \in \mathbb{R}^l$  y  $b \in \mathbb{R}$  parámetros y  $y_i \in \{+1, -1\}$ ,  $i = 1, \dots, n$  las etiquetas de los patrones.

# Maquina de Soporte Vectorial (SVM)

SVM hard-margin primal

SVM con  
Kernel

Héctor  
Maravillo

La **Máquina de Soporte Vectorial (SVM)** busca una solución al siguiente problema de optimización con restricciones:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 \quad (1)$$

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 \quad \forall i = 1, \dots, n \quad (2)$$

Este es un problema de **optimización no lineal (cuadrático)** con un conjunto de **restricciones** formado por desigualdades lineales.

# Maquina de Soporte Vectorial (SVM)

## Lagrangiano

SVM con  
Kernel

Héctor  
Maravillo

Su **función Lagrangiana asociada** es:

$$\mathcal{L}(\mathbf{w}, b, \boldsymbol{\lambda}) = \frac{1}{2} \|\mathbf{w}\|^2 - \sum_{i=1}^n \lambda_i [y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1] \quad (3)$$

$$= \frac{1}{2} \mathbf{w}^T \mathbf{w} - \sum_{i=1}^n \lambda_i [y_i (\mathbf{w}^T \mathbf{x}_i + b) - 1] \quad (4)$$

donde  $\boldsymbol{\lambda} \in \mathbb{R}^n$  es el vector de **multiplicadores de Lagrange**

# Maquina de Soporte Vectorial (SVM)

## Condiciones de KKT

SVM con  
Kernel

Héctor  
Maravillo

Las **condiciones de Karush-Kuhn-Tucker (KKT)**<sup>1</sup> aseguran que un mínimo del problema (1) y (2) debe satisfacer que:

$$\frac{\partial}{\partial \mathbf{w}} \mathcal{L}(\mathbf{w}, b, \lambda) = 0 \quad (5)$$

$$\frac{\partial}{\partial b} \mathcal{L}(\mathbf{w}, b, \lambda) = 0 \quad (6)$$

$$\lambda_i \geq 0, \quad i = 1, \dots, n \quad (7)$$

$$\lambda_i [y_i(\mathbf{w}^T \mathbf{x}_i + b) - 1] = 0, \quad i = 1, \dots, n \quad (8)$$

---

<sup>1</sup>Estas condiciones aseguran condiciones necesarias y suficientes para problemas de optimización no lineal con restricciones de desigualdad.

# Maquina de Soporte Vectorial (SVM)

## Condiciones de KKT

SVM con  
Kernel

Héctor  
Maravillo

Las restricciones anteriores, (5) y (6), equivalen a:

$$\begin{aligned}\mathbf{w} - \sum_{i=1}^n \lambda_i y_i \mathbf{x}_i &= 0 \\ \sum_{i=1}^n \lambda_i y_i &= 0\end{aligned}$$

# Maquina de Soporte Vectorial (SVM)

## Condiciones de KKT

SVM con  
Kernel

Héctor  
Maravillo

Las restricciones anteriores, (5) y (6), equivalen a:

$$\mathbf{w} = \sum_{i=1}^n \lambda_i y_i \mathbf{x}_i$$

$$\sum_{i=1}^n \lambda_i y_i = 0$$

# Maquina de Soporte Vectorial (SVM)

## Notas

SVM con  
Kernel

Héctor  
Maravillo

- La condición (7) asegura que los multiplicadores deben ser cero o positivo, esto significa que el vector  $\mathbf{w}$  de la solución óptima es una combinación lineal de  $n_s \leq n$  vectores de características asociados con los multiplicadores  $\lambda \neq 0$  (restricciones activas). Es decir,

$$\mathbf{w} = \sum_{i=1}^{n_s} \lambda_i y_i \mathbf{x}_i$$

Estos vectores de característica se conocen como **vectores de soporte** y se encuentran en uno de los márgenes. Es decir, son los que se encuentran más cercanos al clasificador lineal.



# Maquina de Soporte Vectorial (SVM)

## Notas

SVM con  
Kernel

Héctor  
Maravillo

- La función de costo (1) es **estrictamente convexa**, debido a que su matriz Hessiana  $H$  es **positiva definida**, esto es:

$$\mathbf{z}^T H \mathbf{z} > 0, \quad \forall \mathbf{z} \in \mathbf{R}^l, \mathbf{z} \neq \mathbf{0}$$

además las restricciones (2) son definidas por desigualdades lineales. Por lo tanto, cualquier **mínimo local** es también es **mínimo global**, y éste es **único**.

# Maquina de Soporte Vectorial (SVM)

## Dual

SVM con  
Kernel

Héctor  
Maravillo

Debido a que el problema de optimización (1), (2) es convexo, la **representación dual de Wolfe**<sup>2</sup> equivale a

$$\max_{\lambda} \mathcal{L}(\mathbf{w}, b, \lambda) \quad (9)$$

$$\mathbf{w} = \sum_{i=1}^n \lambda_i y_i \mathbf{x}_i \quad (10)$$

$$\sum_{i=1}^n \lambda_i y_i = 0 \quad (11)$$

$$\lambda \geq 0 \quad (12)$$

---

<sup>2</sup>El problema dual es una reformulación del problema original (primal) que se basa en el Lagrangiano e introduce variables asociadas a las restricciones.

# Maquina de Soporte Vectorial (SVM)

## Dual

SVM con  
Kernel

Héctor  
Maravillo

Sustituyendo la ecuación (10) y (11) en la función objetivo, y usando un poco de algebra, el **dual Lagrangiano** del **SVM (hard-margin)** es:

$$\max_{\lambda} \left( \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j) \right) \quad (13)$$

$$\sum_{i=1}^n \lambda_i y_i = 0 \quad (14)$$

$$0 \leq \lambda_i \quad i = 1, \dots, n \quad (15)$$

# Maquina de Soporte Vectorial (SVM)

## Notas

SVM con  
Kernel

Héctor  
Maravillo

- Los multiplicadores de Lagrange óptimos  $\lambda^*$  se calculan mediante (13).
- Usando estos valores se puede calcular el vector del hiperplano óptimo  $\mathbf{w}^*$  vía (10).
- El valor del umbral óptimo  $b^*$  se calcula usando los dos resultados anteriores en la restricción (7).

# Maquina de Soporte Vectorial (SVM)

## Notas

SVM con  
Kernel

Héctor  
Maravillo

Hay dos elementos importantes de la formulación dual anterior:

- La función objetivo no depende explícitamente de la dimensión del espacio de entradas, sino del **número de datos** de entrenamiento, ya que  $\lambda \in \mathbb{R}^n$
- La función objetivo sólo depende de los datos de entrenamiento en términos de su **producto punto**.

# Maquina de Soporte Vectorial (SVM)

SVM soft-margin primal

SVM con  
Kernel

Héctor  
Maravillo

En la Máquina de Soporte Vectorial con restricciones suaves, el problema primal es:

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \epsilon_i \quad (16)$$

$$y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \epsilon_i \quad \forall i = 1, \dots, n \quad (17)$$

$$\epsilon_i \geq 0, \quad \forall i = 1, \dots, n \quad (18)$$

donde  $\epsilon_i$  son conocidas como **variables de holgura**.

# Maquina de Soporte Vectorial (SVM)

SVM soft-margin primal

SVM con  
Kernel

Héctor  
Maravillo

El **problema dual** correspondiente equivale a:

$$\max_{\lambda} \left( \sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j (\mathbf{x}_i \cdot \mathbf{x}_j) \right) \quad (19)$$

$$\sum_{i=1}^n \lambda_i y_i = 0 \quad (20)$$

$$0 \leq \lambda_i \leq C \quad i = 1, \dots, n \quad (21)$$

En este caso los multiplicadores de Lagrange que corresponden a los puntos que están en la franja de los márgenes o en el lado incorrecto del clasificador (es decir,  $\epsilon_i > 0$ ) son todos iguales al máximo valor  $C$ .

# Truco del Kernel

SVM con  
Kernel

Héctor  
Maravillo

Si el conjunto de patrones  $X$  no es linealmente separables, el SVM (hard-margin) será incapaz de encontrar un hiperplano óptimo.

Una idea es **mapear** los datos a una **dimensión más alta**, con la **esperanza** que en esa nueva dimensión los datos sean **linealmente separables**.

$$x \in \mathbb{R}^l \rightarrow z \in \mathbb{R}^k, \quad l < k \quad (22)$$

Esta idea tiene dos problemas a resolver:

- ¿Que transformación es la más adecuada?
- ¿Cómo resolver eficientemente el SVM en una dimensión más grande?