

SVM con Kernel

Héctor Maravillo

Producto interno

SVM con
Kernel

Héctor
Maravillo

Sea H un espacio vectorial sobre el campo \mathbb{R} . El **producto escalar**, **producto interno** o **producto punto** sobre H es una aplicación

$$(\cdot, \cdot) : H \times H \mapsto \mathbb{R}$$

que cumple, para todos los vectores $x, y \in H$ y cualquier escalar $\alpha \in \mathbb{R}$, las siguientes propiedades:

$$(x, y) = (y, x)$$

$$(x, y + z) = (x, y) + (x, z)$$

$$(\alpha x, y) = \alpha(x, y)$$

$$(x, x) \geq 0$$

$$(x, x) = 0 \Leftrightarrow x = 0$$

Espacio pre-hilbertiano

SVM con
Kernel

Héctor
Maravillo

A los espacios con **producto interno** se les conoce como **espacios pre-hilbertianos**. Son una generalización de los espacios euclidianos y su estructura permite **medir ángulos y longitudes** en el espacio vectorial.

Norma cuadrática

SVM con
Kernel

Héctor
Maravillo

Sea H un espacio vectorial dotado de un producto punto. Se denomina **norma (norma cuadrática)** de un número $x \in H$ al número real no negativo:

$$\|x\| = \sqrt{(x, x)}$$

Sea H un espacio vectorial dotado de una norma $\|x\|$. La función:

$$d : (x, y) \in H \times H \mapsto \mathbb{R} \quad (1)$$

$$d(x, y) := \|x - y\| \quad (2)$$

es una **distancia** sobre H .

Espacios métricos

SVM con
Kernel

Héctor
Maravillo

A la tupa (X, d) donde X es un conjunto de objetos (puntos) y $d : X \times X \mapsto \mathbb{R}$ es una función que cumple que:

$$d(x, y) \geq 0$$

$$d(x, y) = 0 \Leftrightarrow x = y$$

$$d(x, y) = d(y, x)$$

$$d(x, y) \leq d(x, z) + d(z, y)$$

(denominada **métrica** o **distancia**) se le denomina **espacio métrico**.

Todo espacio X con una norma da lugar a un espacio métrico (X, d) definiendo:

$$d(x, y) := \|x - y\|, \quad x, y \in X$$

Convergencia en espacios métricos

SVM con
Kernel

Héctor
Maravillo

Sea (X, d) un espacio métrico y $(x_n) \subset X$ una sucesión.

- La sucesión es **convergente** si existe un elemento $x_0 \in X$ tal que: $d(x_n, x_0) \rightarrow 0$ cuando $n \rightarrow \infty$. Es decir:

$$\lim_{n \rightarrow \infty} x_n = x_0$$

- La sucesión es **de Cauchy** cuando, dado $\epsilon > 0$ existe $n_0 \in \mathbb{N}$ tal que $d(x_m, x_n) < \epsilon$ para todo $m, n \geq n_0$.

Toda sucesión convergente es de Cauchy, pero en ciertos espacios no toda sucesión de Cauchy es sucesión convergente.

Espacios de Hilbert

SVM con
Kernel

Héctor
Maravillo

Un espacio métrico (X, d) se dice que es **completo** si toda sucesión de Cauchy es convergente.

Se dice que un espacio con producto interno $(X, (\cdot, \cdot))$ es un **espacio de Hilbert** si el espacio métrico (X, d) es completo, con

$$\begin{aligned} \|x\| &:= \sqrt{(x, x)} \\ d(x, y) &:= \|x - y\|, \quad x, y \in X \end{aligned}$$

Espacios de Hilbert

SVM con
Kernel

Héctor
Maravillo

Ejemplos de **espacios de Hilbert**:

- Espacios euclidianos \mathbb{R}^n con punto interno

$$(x, y) := \sum_{i=1}^n x_i y_i$$

.

Espacios de Hilbert

SVM con
Kernel

Héctor
Maravillo

- El espacio de sucesiones

$$l_2 := \left\{ x = (x_k) \in \mathbb{R}^n : \sum_{k=1}^{\infty} |x_k|^2 < \infty \right\}$$

con producto interno:

$$(x, y) := \sum_{i=1}^{\infty} x_i y_i$$

.

Espacios de Hilbert

SVM con
Kernel

Héctor
Maravillo

- Espacios de funciones L^2 (funciones definidas en $[a, b]$ tal que la integral de $|f(x)|^2$ es finita) con producto interno:

$$(f, g) := \int_a^b f(x)g(x)dx$$

Teorema de Mercer

SVM con
Kernel

Héctor
Maravillo

Theorem

Sea $x \in \mathbb{R}^l$ y Φ un mapeo $x \mapsto \Phi(x) \in H$ donde H es un espacio de Hilbert. El **producto interno** en H tiene una **representación equivalente**, es decir:

$$(\Phi(x), \Phi(z)) = K(x, z), \quad x, z \in \mathbb{R}^l \quad (3)$$

donde $K(x, z)$ es una función **simétrica** y **continua** que satisface la siguiente condición:

$$\int_C \int_C K(x, z) g(x) g(z) dx dz \geq 0 \quad (4)$$

para cualquier función $g(x)$, $x \in C \subset \mathbb{R}^l$ tal que

$$\int_C g(x)^2 dx < \infty$$

donde C es un subconjunto compacto de \mathbb{R}^l

Teorema de Mercer

SVM con
Kernel

Héctor
Maravillo

La afirmación inversa al teorema anterior también siempre es cierta, esto es: Para cualquier función simétrica y continua $K(x, z)$ que satisface (3) y (4) **existe** un espacio en el cual $K(x, z)$ define un producto interno.

Las funciones que cumplen con esas condiciones son conocidas como **Kernels** y el espacio H como **Espacios de Hilbert con núcleo reproductor** (*reproducing kernel Hilbert space RKHS*).

Kernels

SVM con
Kernel

Héctor
Maravillo

El teorema de Mercer **no dice como encontrar** esos espacios, solo **asegura que existen**.

No existe una herramienta general para construir el mapeo $\Phi()$ una vez que conocemos el producto interno de su espacio correspondiente.

Tampoco podemos conocer, en general, la dimensión del espacio H incluso, la cual podría ser infinita.

Construcción de Kernels

SVM con
Kernel

Héctor
Maravillo

Una **condición necesaria y suficiente** para que una función $K(x, z)$ sea un kernel válido es que la **matriz de Gramm \mathbf{K}** , cuyos elementos son $k(x_i, x_j)$ con $x_i, x_j \in X$ sea una **matriz semidefinida positiva**, es decir que:

$$\mathbf{v}^T \mathbf{K} \mathbf{v} \geq 0, \quad \mathbf{v} \in \mathbb{R}^l$$

Otra técnica poderosa es construir nuevos Kernels a partir de Kernels simples conocidos, usando las siguientes reglas.

Construcción de Kernels

SVM con
Kernel

Héctor
Maravillo

Sea $K(x, z)$ un kernel, entonces las siguientes funciones también son kernels:

$$K_1(x, z) = cK(x, z)$$

$$K_1(x, z) = f(x)K(x, z)f(z)$$

$$K_1(x, z) = q(K(x, z))$$

$$K_1(x, z) = \exp(K(x, z))$$

donde $c > 0$ es una constante, f es cualquier función, q es un polinomio con coeficientes no negativos.

Construcción de Kernels

SVM con
Kernel

Héctor
Maravillo

Sea $K_1(x, z)$ y $K_2(x, z)$ dos kernels, entonces, las siguientes funciones también son kernels:

$$K_3(x, z) = K_1(x, z) + K_2(x, z)$$

$$K_3(x, z) = K_1(x, z)K_2(x, z)$$

Ejemplo

SVM con
Kernel

Héctor
Maravillo

Sea

$$K(x, z) = (x^T z + 1)^2$$

con $x, z \in \mathbb{R}^2$ entonces

$$\begin{aligned} k(x, z) &= (x_1 y_1 + x_2 y_2 + 1)^2 \\ &= x_1^2 y_1^2 + x_2^2 y_2^2 + 1 + 2x_1 y_1 x_2 y_2 + 2x_1 y_1 + 2x_2 y_2 \end{aligned}$$

Esto corresponde al producto interno de

$$\Phi(x) = (1, \sqrt{2}x_1, \sqrt{2}x_2, \sqrt{2}x_1x_2, x_1^2, x_2^2)^T$$

Truco del Kernel

SVM con
Kernel

Héctor
Maravillo

Para utilizar el truco del Kernel hay que definir una función de Kernel válida.

- Un enfoque es elegir un mapeo $\Phi(x)$ del espacio de atributos y usar su producto interno para encontrar un Kernel, es decir, definir

$$K(x, z) = \Phi(x)^T \Phi(z)$$

- Otro enfoque, es construir una función de Kernel directamente, sin preocuparse de identificar cual es el espacio H correspondiente.

Truco del Kernel

SVM con
Kernel

Héctor
Maravillo


El concepto de un Kernel correspondiente al producto interno en un espacio de características permite **construir extensiones de algoritmos lineales**, haciendo uso del **truco del kernel** o **sustitución Kernel**.

La idea general es: si tenemos un algoritmo formulado de forma que el vector de entradas x participa sólo en forma de productos internos, podemos **reemplazar el producto interno** por una función de Kernel.

Truco del Kernel

SVM con
Kernel

Héctor
Maravillo



SVM con kernel

SVM con
Kernel

Héctor
Maravillo

Una vez elegido un kernel apropiado, este define un mapeo en un espacio de mayor dimensión (un RKHS), y el modelo de optimización dual de Wolfe correspondiente se convierte en:

$$\begin{aligned} \max_{\lambda} \quad & \left(\sum_{i=1}^n \lambda_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \lambda_i \lambda_j y_i y_j K(\mathbf{x}_i, \mathbf{x}_j) \right) \\ \sum_{i=1}^n \lambda_i y_i &= 0 \\ 0 \leq \lambda_i &\leq C \quad i = 1, \dots, n \end{aligned}$$

SVM con kernel

SVM con
Kernel

Héctor
Maravillo

A partir de los multiplicadores de Lagrange óptimos encontrados en el problema anterior, el clasificador lineal en el espacio RKHS consiste en:

- Asignar x en la clase ω_1 si

$$g(x) = \sum_{i=1}^{N_s} \lambda_i y_i K(x_i, x) + b > 0$$

- Asignar a ω_2 en caso contrario.

Debido a la no linealidad de la función de Kernel, el clasificador resultante es no lineal en el espacio \mathbb{R}^l original.

SVM con Kernel

Ventajas

SVM con
Kernel

Héctor
Maravillo

- La **complejidad computacional** es **independiente** de la **dimensión del espacio del Kernel**, donde el espacio de atributos es mapeado, debido al truco del Kernel.
- Uno resuelve un SVM en un espacio de alta dimensión sin tener que adoptar explícitamente el modelo en ese espacio con un gran número de parámetros.
- Por estas cuestiones, el SVM tiende a mostrar un buen rendimiento.

SVM con Kernel

Limitaciones

SVM con
Kernel

Héctor
Maravillo

- La principal limitación es que no existe ningún método práctico eficiente para seleccionar la mejor función de Kernel.
- Una vez seleccionada la función de Kernel, es necesario definir sus parámetros, así como el parámetro de suavizado C .